

Modelos PLS generalizados con aplicaciones en R.

Andrés Felipe Ochoa Muñoz
April 15, 2026

andres.ochoa@correounivalle.edu.co

ESCUELA DE ESTADISTICA, FACULTAD DE INGENIERIA

1. Introducción
2. Métodos PLS
3. Software
4. Ejemplos de Aplicación
5. Conclusiones y Trabajos Futuros

Introducción

Considere las variables centradas: $Y, X_1, \dots, X_j, \dots, X_p$. La regresión por mínimos cuadrados parciales (PLS) es un modelo que permite construir componentes ortogonales t_h obtenidas maximizando las cantidades $\text{cov}(Y, t_h)$.

La Regresión PLS ha sido descrita por Lindberg et al. (1983), Geladi and Kowalski (1986), Höskuldsson (1988), Tenenhaus (1998) y Wold et al. (2001).

Se han realizado diversas aplicaciones del PLS en las áreas de quimiometría, genética y sensometría. Donde los datos son caracterizados por un lote de variables medidas sobre pocas observaciones ($p > n$) (González Rojas, 2014).

En este tipo de datos suele presentarse problemas de alta correlación en las variables explicativas $X_{(n \times p)}$, lo cuál conlleva a **multicolinealidad** y esto generará mayor varianza en los estimadores de los coeficientes de regresión.

El modelo PLS plantea solucionar la multicolinealidad al utilizar componentes **PLS ortogonales t_h que tengan máxima correlación con la variable respuesta Y .**

PLS ha tenido gran impacto en la modelación estadística, puesto que se han realizado extensiones en modelos avanzados, tales como:

- Modelos PLS generalizados (PLS-GLR o PLS-GLM) (Bastien et al., 2005).

PLS ha tenido gran impacto en la modelación estadística, puesto que se han realizado extensiones en modelos avanzados, tales como:

- Modelos PLS generalizados (PLS-GLR o PLS-GLM) (Bastien et al., 2005).
- Regresión PLS para datos funcionales (Preda et al., 2007).

PLS ha tenido gran impacto en la modelación estadística, puesto que se han realizado extensiones en modelos avanzados, tales como:

- Modelos PLS generalizados (PLS-GLR o PLS-GLM) (Bastien et al., 2005).
- Regresión PLS para datos funcionales (Preda et al., 2007).
- Modelos de espacio estado via PLS (Patel et al., 2020).

PLS ha tenido gran impacto en la modelación estadística, puesto que se han realizado extensiones en modelos avanzados, tales como:

- Modelos PLS generalizados (PLS-GLR o PLS-GLM) (Bastien et al., 2005).
- Regresión PLS para datos funcionales (Preda et al., 2007).
- Modelos de espacio estado via PLS (Patel et al., 2020).
- Regresión PLS beta (Bertrand et al., 2013).

PLS ha tenido gran impacto en la modelación estadística, puesto que se han realizado extensiones en modelos avanzados, tales como:

- Modelos PLS generalizados (PLS-GLR o PLS-GLM) (Bastien et al., 2005).
- Regresión PLS para datos funcionales (Preda et al., 2007).
- Modelos de espacio estado via PLS (Patel et al., 2020).
- Regresión PLS beta (Bertrand et al., 2013).
- Regresión PLS-Birnbaum-Sanders (Huerta et al., 2019).

PLS ha tenido gran impacto en la modelación estadística, puesto que se han realizado extensiones en modelos avanzados, tales como:

- Modelos PLS generalizados (PLS-GLR o PLS-GLM) (Bastien et al., 2005).
- Regresión PLS para datos funcionales (Preda et al., 2007).
- Modelos de espacio estado via PLS (Patel et al., 2020).
- Regresión PLS beta (Bertrand et al., 2013).
- Regresión PLS-Birnbaum-Sanders (Huerta et al., 2019).
- Regresión PLS bajo la distribución skew-normal y skew- t (Ochoa-Muñoz et al., 2025).

Métodos PLS

Sea T la matriz formada por estas componentes, se tiene el modelo PLS dado por:

$$Y = Tc^T + \epsilon, \quad (1)$$

Donde ϵ es el vector de residuos y c^T es el vector de coeficientes de los componentes. Al postular $T = XW^*$, donde W^* es la matriz de los coeficientes de las variables x_j en cada componente t_h , tenemos la expresión directa para la respuesta Y usando los predictores x_j :

$$Y = XW^*c^T + \epsilon \quad (2)$$

Expandiendo la ecuación anterior se tiene que:

$$Y_i = \sum_{h=1}^H (c_h w_{1h}^* x_{i1} + \dots + c_h w_{ph}^* x_{ip}) + \epsilon_i \quad (3)$$

Donde H es el número de componentes retenidos en el modelo final con $H \leq \text{rango}(X)$. Además, p es el número de variables de la matriz X .

Los coeficientes $c_h w_{jh}^*$ muestran la relación entre el vector Y y las variables x_j a través de las componentes t_h .

PLS (Partial Least Squares)

El siguiente algoritmo 1 es adaptado de Garthwaite (1994); Vega-Vilca and Guzmán (2011). La entrada de datos corresponde a la matriz $X_{(n \times p)}$ y el vector respuesta $Y_{(n \times 1)}$, los cuales han sido estandarizados por columna.

Algorithm 1 Algoritmo PLS

Ensure: $X_0 = X, Y_0 = Y$

- 1: **for** $h = 1$ to H **do**
 - 2: Calcular $\mathbf{a}_h = \text{Cov}(\mathbf{Y}_{h-1}, \mathbf{X}_{h-1})$
 - 3: Calcular $\mathbf{W}_h^* = \|\mathbf{a}_h\|^{-1} \mathbf{a}_h$, donde $\|\mathbf{a}_h\| = \sqrt{\mathbf{a}_{1h}^2 + \mathbf{a}_{2h}^2 + \dots + \mathbf{a}_{ph}^2}$
 - 4: $\mathbf{T}_h = \mathbf{X}_{h-1} \mathbf{W}_h^*$
 - 5: $\mathbf{c}_h = \frac{\mathbf{T}_h^\top \mathbf{Y}_{h-1}}{\mathbf{T}_h^\top \mathbf{T}_h}$
 - 6: $\mathbf{v}_h = \frac{\mathbf{T}_h^\top \mathbf{X}_{h-1}}{\mathbf{T}_h^\top \mathbf{T}_h}$
 - 7: Actualizar $\mathbf{X}_h = \mathbf{X}_{h-1} - \mathbf{T}_h \mathbf{p}_h$
 - 8: Actualizar $\mathbf{Y}_h = \mathbf{Y}_{h-1} - \mathbf{T}_h \mathbf{c}_h$
 - 9: **end for**
-

- a : es un vector de covarianzas entre Y e X .
- w : es un vector propio que se utiliza para construir las componentes PLS t_h .
- T : son las componentes PLS (scores).
- p : coeficientes que relacionan las componentes PLS con las variables explicativas X . (loadings)
- c : coeficientes que relacionan las componentes PLS con la variable respuesta Y . (loadings)
- $h = 1, \dots, H$: son los ejes factoriales.

Se puede escribir la fórmula de regresión de Y sobre las componentes $t_1, \dots, t_H$ en función de las variables X , entonces:

$$\hat{Y} = T_h c_h = t_1 c_1 + \dots + t_H c_H \quad (4)$$

$$= XW_h^* c_h \quad (5)$$

$$= XW_h(p_h' W_h)^{-1} c_h = X\hat{\beta}_h \quad (6)$$

Donde $\hat{\beta}_h = W_h(p_h' W_h)^{-1} c_h$ es el vector estimado de coeficientes de regresión PLS de Y sobre X utilizando h componentes.

Se ha demostrado que la regresión PLS se puede obtener utilizando métodos simples y múltiples de regresión. Si estas regresiones son reemplazadas por modelos lineales de regresión generalizados (GLM), se tiene entonces una nueva serie de modelos: PLS-GLM(Bastien et al., 2005).

La regresión PLS-GLM de Y sobre $X_1, X_2, \dots, X_p$ con H componentes se escribe cómo:

$$g(\theta) = \sum_{h=1}^H c_h \left(\sum_{j=1}^p w_{hj}^* X_j \right) \quad (7)$$

1. Inicializar $\mathbf{X}_0^* = \mathbf{X}^*$ y $\mathbf{Y}_0 = \mathbf{Y}$.
2. Calcular la primera componente PLS $\mathbf{t}_1$ con los siguientes pasos:
 - 2.1 Estimar el coeficiente a_{1j} de $\mathbf{X}_j^*$ en la regresión GLM de $\mathbf{Y}$ sobre $\mathbf{X}_j^*$, basado en la estimación por máxima verosimilitud (MLE), con $\mu_i = g^{-1}(a_{1j}\mathbf{X}_{ji}^*)$, para $i = 1, \dots, n$. Repetir este paso para $j = 1, \dots, p$, obteniendo $\mathbf{a}_1 = (a_{11}, \dots, a_{1p})^\top$.
 - 2.2 Calcular el primer vector columna de $\mathbf{W}^*$ como $\mathbf{W}_1^* = \|\mathbf{a}_1\|^{-1}\mathbf{a}_1$.
 - 2.3 Determinar la primera componente PLS como $\mathbf{t}_1 = \mathbf{X}_0^* \mathbf{W}_1^*$.
 - 2.4 Definir la matriz residual $\mathbf{X}_1^* = \mathbf{X}_0^* - \mathbf{t}_1 \mathbf{W}_1^*$.

3. Calcular la segunda componente PLS $\mathbf{t}_2$ con los siguientes pasos:

3.1. Estimar el coeficiente a_{2j} de $\mathbf{X}_j^*$ en la regresión GLM de $\mathbf{Y}$ sobre $\mathbf{X}_j^*$, basado en la estimación por máxima verosimilitud (MLE), con $\mu_i = g^{-1}(a_{1j}t_{1i} + a_{2j}x_{ji}^*)$, para $i = 1, \dots, n$. Repetir este paso para $j = 1, \dots, p$, obteniendo $\mathbf{a}_2 = (a_{21}, \dots, a_{2p})^\top$.

3.2. Calcular el segundo vector columna de $\mathbf{W}^*$ como $\mathbf{W}_2^* = \|\mathbf{a}_2\|^{-1}\mathbf{a}_2$.

3.3. Determinar la segunda componente PLS como $\mathbf{t}_2 = \mathbf{X}_1^* \mathbf{W}_2^*$.

3.4. Definir la matriz residual $\mathbf{X}_2^* = \mathbf{X}_1^* - \mathbf{t}_2 \mathbf{W}_2^*$.

4. Determinar el número óptimo $H \leq p = \text{rank}(\mathbf{X})$ de componentes PLS, y calcular las componentes PLS subsecuentes $\mathbf{t}_h$ para $h = 3, \dots, H$, con los siguientes pasos:

4.1. Estimar el coeficiente a_{hj} de $\mathbf{X}_j^*$ en la regresión GLM de $\mathbf{Y}$ sobre $\mathbf{X}_j^*$, basado en la estimación por máxima verosimilitud (MLE), con $\mu_i = g^{-1}(a_{1j}t_{1i} + \dots + a_{(H-1)j}t_{(H-1)i} + a_{Hj}\mathbf{X}_{ji}^*)$, para $i = 1, \dots, n$. Repetir este paso para $j = 1, \dots, p$, obteniendo $\mathbf{a}_H = (a_{H1}, \dots, a_{Hp})^\top$.

4.2. Calcular el vector columna H -ésimo de $\mathbf{W}^*$ como $\mathbf{W}_H^* = \|\mathbf{a}_H\|^{-1}\mathbf{a}_H$.

4.3. Determinar la componente PLS H -ésima como $\mathbf{t}_H = \mathbf{X}_{H-1}^* \mathbf{W}_H^*$.

4.4. Definir la matriz residual $\mathbf{X}_H^* = \mathbf{X}_{H-1}^* - t_H \mathbf{W}_H^*$.

5. Completar las matrices $\mathbf{T}$ y $\mathbf{W}$ generadas en los Pasos 2-4.
6. Estimar el vector de coeficientes $\mathbf{q}$ como $\hat{\mathbf{q}} = (\hat{q}_0, \dots, \hat{q}_H)^\top$, donde $\hat{\mathbf{q}}$ se obtiene de la regresión GLM de $\mathbf{Y}$ sobre $\mathbf{T}_H$.
7. Calcular los coeficientes $\boldsymbol{\beta} = (\beta_0, \boldsymbol{\beta}_j^\top)$, donde $\hat{\beta}_0 = \hat{q}_0$ y $\hat{\boldsymbol{\beta}}_j^\top = \mathbf{W}\hat{\mathbf{q}}^*$, con $\hat{\mathbf{q}}^* = (\hat{q}_1, \dots, \hat{q}_H)^\top$. Así, $\hat{\boldsymbol{\beta}}$ son los coeficientes del modelo PLS-GLM.
8. Predecir la respuesta $\mathbf{Y}$ usando el modelo PLS-GLM como $\hat{\mathbf{Y}}_{\text{pred}} = g^{-1}(\mathbf{X}_{\text{pred}}^\top \hat{\boldsymbol{\beta}})$, donde $\mathbf{X}_{\text{pred}}$ son las covariables observadas para la predicción y $\hat{\boldsymbol{\beta}}$ corresponde a los estimadores PLS del modelo $\hat{\mathbf{Y}} = g^{-1}(\mathbf{X}^\top \hat{\boldsymbol{\beta}})$

Este enfoque fue propuesto por Lazraq et al. (2003) y ha sido estudiado en detalle por Bertrand et al. (2014).

Este enfoque puede utilizarse para calcular intervalos de confianza para los coeficientes β del modelo PLS-GLM, permitiendo así determinar las variables significativas con un nivel de confianza de $(1 - \alpha)$ (Bastien et al., 2005).

Algorithm 2 Selección de variables significativas utilizando Bootstrap

Require: Conjunto de datos (Y, X) , número de muestras Bootstrap B , número de componentes H .

- 1: **for** $b = 1$ to B **do**
 - 2: Obtener una muestra bootstrap de tamaño n : (Y^b, X^b) .
 - 3: Calcular $\hat{\beta}^b$ ajustando el modelo PLS-GLM con H componentes a la muestra (Y^b, X^b) .
 - 4: **end for**
 - 5: **for** $j = 1$ to p **do**
 - 6: Definir $E_j = (\hat{\beta}_j^1, \hat{\beta}_j^2, \dots, \hat{\beta}_j^B) \in M_{1 \times B}$ como el vector Bootstrap de tamaño B para $\hat{\beta}_j$, el coeficiente estimado de X_j en la regresión PLS-GLM.
 - 7: Calcular un intervalo de confianza I_j^B para β_j .
 - 8: **if** $0 \in I_j^B$ **then**
 - 9: La variable X_j no es significativa.
 - 10: **end if**
 - 11: **end for**
 - 12: **return** Lista de variables significativas.
-

Software

Algunas librerías para el ajuste de modelos PLS.

- `library(chemometrics)`: Incluye `nipals`, `PLS1`, `PLS2`.
- `library(plsdepot)`: Incluye `nipals`, `PLS1`, `PLS2`.
- `library(plsRglm)`: Incluye regresión gaussiana, regresión logística, regresión poisson, regresión gamma, entre otras. Bajo el enfoque PLS.
- `library(plsRbeta)`: Incluye Regresión PLS Beta.

Ejemplos de Aplicación

Ejemplo 1: Regresión Logística PLS (PLS-GLM-BINOM)

El conjunto de datos *Pima.tr* de la librería *MASS* de *R*. Tiene 200 muestras de mujeres, el objetivo es determinar la probabilidad de que una mujer tenga diabetes con base a un grupo de variables explicativas $X_{(n \times p)}$. De esta forma, las variables son:

- npreg: cantidad de embarazo
- glu: concentración de glucosa en plasma en una prueba oral de tolerancia a la glucosa.
- bp: presión arterial diastólica (mm Hg).
- skin: espesor del pliegue de la piel del tríceps (mm).
- bmi: índice de masa corporal.
- ped: función de pedigrí de la diabetes.
- age: edad en años
- type: Sí o No, para diabéticos según los criterios de la OMS

Ejemplo 1: ¿Cómo comparar los Modelos?

La idea con este ejemplo es comparar la Regresión Logística vs PLS-GLM-BINOM. Para la comparación de los modelos se utilizan los criterios de información AIC y BIC. Además, se utiliza el porcentaje de datos bien clasificados mediante la matriz de confusión.

Para el ajuste del modelo PLS-GLM-BINOM, se utiliza:

```
ifelse(Pima.trtype == "Yes", 1, 0); X = Pima.tr[, -8];  
modPLS.Binom = plsRglm(y, X, 3, modele = "pls-glm-logistic")
```

Ejemplo 1: Comprendiendo los datos mediante ACP




Figure 1: ACP datos Pima.tr.

No - 0.66 ; Yes: 0.34

$$vif_{npreg} = 1.520; vif_{glu} = 1.089; vif_{bp} = 1.251;$$

$$vif_{skin} = 1.761; vif_{bmi} = 1.742; vif_{ped} = 1.077$$

$$vif_{age} = 1.702$$

$$AIC = 194.390; BIC = 220.777$$

Ejemplo 1: Ajuste PLS-GLM-BINOM y determinación de H .




Figure 2: AIC y BIC en el modelo PLS-GLM-BINOM.tr.

Model	AIC	BIC	Accuracy
Regresión Logística	194.390	220.777	0.775
PLS-GLM-BINOM	185.050	194.945	0.78

Table 1: Comparación del ajuste de los modelos Regresión Logística y PLS-GLM.

Ejemplo 2: PLS basado en la distribución Gamma.

El conjunto de datos *Boston* de la librería $\widehat{\text{MASS}}$ del software *R*. Este consta de 506 muestras, y el objetivo de estos datos es modelar la variable $Y = \text{precio medio de la vivienda en miles de dolares (medv)}$ en función de las siguientes variables:

- X_1 = Tasa de criminalidad per cápita por municipio (crim).
- X_2 = Proporción de acres destinados a negocios no minoristas por municipio (indus).
- X_3 = Concentración de óxidos de nitrógeno en partes por 10 millones (nox).
- X_4 = Número promedio de habitaciones por vivienda.(rm)
- X_5 = Media ponderada de las distancias a cinco centros de empleo (dis).
- X_6 = Índice de accesibilidad a las autopistas (rad).

1. Análisis descriptivo.
2. Ajuste por MCO, calculo de IC clásicos y análisis vif.
3. Ajuste del modelo PLS y PLS-GLR con $h = 1, 2, \dots$ componentes.
4. Determinar el número de componentes H mediante los criterios AIC y BIC.
5. Construir intervalos de confianza basados en el método normal, percentil y en el método BCa para seleccionar las covariables que sean significativas a un nivel de significancia de $\alpha = 0.05$.
6. Finalmente, se analiza el ajuste del mejor modelo encontrado en los pasos anteriores.

Ejemplo 2: Variable respuesta medv

$$\bar{y} = 22.53; \sigma_y = 9.197; \gamma_y = 1.108; \alpha_{4y} = 1.451.$$




Figure 3: Comportamiento de la variable respuesta medv.

Ejemplo 2: Ajuste por MCO

	Estimate	Std. Error
(Intercept)	-7.5184	4.0788
crim	-0.1796	0.0398
indus	-0.2401	0.0671
nox	-16.0409	4.2522
rm	7.4117	0.4144
dis	-1.0205	0.2077
rad	-0.0456	0.0458

Table 2: Resumen para el modelo MCO.


	2.5 %	97.5 %
(Intercept)	-15.53	0.50
crim	-0.26	-0.10
indus	-0.37	-0.11
nox	-24.40	-7.69
rm	6.60	8.23
dis	-1.43	-0.61
rad	-0.14	0.04

Table 3: IC clásicos con $\alpha = 0.05$.

$$vif_{crim} = 1.682; vif_{indus} = 3.051; \text{vif}_{nox} = 3.493;$$

$$vif_{rm} = 1.219; vif_{dis} = 2.753; vif_{rad} = 2.293$$

Ejemplo 2: Ajuste del Modelo PLS vs PLS-GLM



Ejemplo 2: Bootstrap Modelo PLS-GLM-Gamma




Figure 5: Intervalos de Confianza Bootstrap para el modelo PLS-GLM-GA.

Model	AIC	BIC
MCO con todas las variables	3245.316	3279.129
PLS con todas las variables	3241.159	3262.292
PLS-GLM-GA con todas las variables	3124.638	3141.544
MCO sin X_6	3244.317	3273.903
PLS sin X_6	3240.764	3261.897
PLS-GLM-GA sin X_6	3118.943	3135.85

Table 4: Comparación del ajuste de los modelos MCO, PLS, PLS-GLM.

Ejemplo 2: Ajuste Final del Modelo.




Figure 6: Ajuste del Modelo PLS-GLM-GA.

Conclusiones y Trabajos Futuros

- Los modelos PLS generalizados (PLS-GLR o PLS-GLM) pueden presentar mejor ajuste que los modelos MCO y PLS. Esto sucede en escenarios donde se presente multicolinealidad.
- Se puede extender los modelos PLS para trabajar con otras distribuciones por ejemplo: la distribución kumaraswamy, la skew-cauchy, entre otras.
- También podría pensarse un enfoque del modelo PLS combinado con Redes Neuronales, tal como sugieren Qin and McAvoy (1992).

Consultar el repositorio con las diapositivas y códigos de R:

<https://github.com/AndresOchoaRSA/PLS-GLM>

Referencias

References

- Bastien, P., Vinzi, V. E., and Tenenhaus, M. (2005). Pls generalised linear regression. *Computational Statistics & data analysis*, 48(1):17–46.
- Bertrand, F., Magnanensi, J., Meyer, N., and Maumy-Bertrand, M. (2014). plsrglm: Algorithmic insights and applications. *Edited: June*.
- Bertrand, F., Meyer, N., El Bayed, K., Namer, I.-J., Maumy-Bertrand, M., et al. (2013). Régression bêta pls. *Journal de la Société Française de Statistique*, 154(3):143–159.
- Garthwaite, P. H. (1994). An interpretation of partial least squares. *Journal of the American Statistical Association*, 89(425):122–127.
- Geladi, P. and Kowalski, B. R. (1986). Partial least-squares regression: a tutorial. *Analytica chimica acta*, 185:1–17.
- González Rojas, V. M. (2014). Análisis conjunto de múltiples tablas de datos mixtos mediante pls.
- Höskuldsson, A. (1988). Pls regression methods. *Journal of chemometrics*, 2(3):211–228.

- Huerta, M., Leiva, V., Liu, S., Rodríguez, M., and Villegas, D. (2019). On a partial least squares regression model for asymmetric data with a chemical application in mining. *Chemometrics and Intelligent Laboratory Systems*, 190:55–68.
- Lazraq, A., Cleroux, R., and Gauchi, J.-P. (2003). Selecting both latent and explanatory variables in the pls1 regression model. *Chemometrics and Intelligent Laboratory Systems*, 66(2):117–126.
- Lindberg, W., Persson, J.-A., and Wold, S. (1983). Partial least-squares method for spectrofluorimetric analysis of mixtures of humic acid and lignin sulfonate. *Analytical Chemistry*, 55(4):643–648.
- Ochoa-Muñoz, A. F., Contreras-Reyes, J. E., Mosquera, J., and Salas, R. (2025). Partial least squares models under skew-normal and skew-t settings with applications. *Chemometrics and Intelligent Laboratory Systems*, 264:105438.
- Patel, N., Mhaskar, P., and Corbett, B. (2020). Subspace based model identification for missing data. *AIChE Journal*, 66(10):e16538.
- Preda, C., Saporta, G., and Lévéder, C. (2007). Pls classification of functional data. *Computational Statistics*, 22(2):223–235.
- Qin, S. J. and McAvoy, T. J. (1992). Nonlinear pls modeling using neural networks. *Computers & Chemical Engineering*, 16(4):379–391.

Tenenhaus, M. (1998). *La régression PLS, théorie et pratique*.

Vega-Vilca, J. C. and Guzmán, J. (2011). Regresión pls y pca como solución al problema de multicolinealidad en regresión múltiple. *Revista de Matemática: Teoría y Aplicaciones*, 18(1):9–20.

Wold, S., Sjöström, M., and Eriksson, L. (2001). Pls-regression: a basic tool of chemometrics. *Chemometrics and intelligent laboratory systems*, 58(2):109–130.

Gracias!